

# Inferență statistică în ML

Cap 1. Introducere. Probabilitate. Probabilități condiționate. Valoare așteptată.

March 3, 2019

- 1 Introducere
- 2 Probabilitate
- 3 Probabilități condiționate
- 4 Independență statistică
- 5 Problema Monty Hall

# Scop

Cursul își propune introducerea noțiunilor fundamentale ce permit abordarea datelor într-un mod științific.

Se vor introduce uneltele necesare pentru analiza datelor, pornind de la datele stocate în baza de date până la realizarea de grafice interactive.

Se prezintă fundamentele inferenței statistice: scopul, modelele și presupunerile inferenței statistice. Ca rezultat, se deprind abilitățile de a realiza raționamente de inferență în diverse situații și pentru ML în special.

# Inferența statistică

- **Inferența statistică:** procesul de generare de concluzii despre o populație pornind de la un sample (noisy)
- se generează concluzii noi pornind de la date
- sistem formal de inferență
- exemplu 1: câștigătorul alegerilor următoare, pornind de la sample-ul votanților actuali
  - noisy sample: unii nu vor vota, alții se vor răzgândi, alții vor minți
  - eliminăm incertitudinea
- exemplu 2: probabilitatea ca mâine să plouă este 70% - asociază o probabilitate unui eveniment

# Paradigme inferențiale

- există două abordări pentru inferența statistică:
  - 1 abordarea frecventistă
  - 2 abordarea bayesiană
- abordarea frecventistă este fundația pentru raționamentele de inferență statistică



- abordarea probabilității din punctul de vedere al analizei numărului de ori al obținerii capului la aruncarea unei monede ideale (Head = cap, Tail = stema)
- experiment repetat, într-un anumit procent de cazuri ceva se întâmplă - parametru al populației
- [https://en.wikipedia.org/wiki/Fair\\_coin](https://en.wikipedia.org/wiki/Fair_coin)

# Exemple de probleme de cauzalitate

- cu ajutorul inferenței statistice se pot construi raționamente care să ilustreze cauzalitatea, și nu doar asocierea
  - ❶ provoacă fumatul cancer?
  - ❷ o campanie de reclamă determină creșterea traficului web?
  - ❸ un tratament nou este chiar util pentru vindecarea bolii respective?
- cursul se concentrează pe construirea de modele frecventiste și testarea asumpțiilor
- ne concentrăm mai mult pe concepte
- quiz-uri, teme de casă

# Noțiunea de probabilitate

- **probabilitatea** asociază un număr între 0 și 1 unui eveniment, pentru a da un sens noțiunii de “șansă” de producere a acelui eveniment
- probabilitatea modelează ceea ce par a fi fenomene întâmplătoare (aleatoare)
- scopul final este de a folosi un model probabilist, pentru a trage concluzii pornind de la un sample al unei populații
- există un set de reguli pe care noțiunea de probabilitate le îndeplinește

## Probabilitate (2)

- pentru un experiment aleator, de exemplu aruncarea cu zarul, o măsură a probabilității este o cantitate asociată **populației** care sumarizează caracterul aleator
- probabilitatea este asociată intrinsec populației, este o proprietate a ei, pe care dorim să o estimăm
- probabilitatea ia fiecare eveniment posibil care se produce în urma experimentului și îi asociază o valoare numerică





# Aruncarea cu zarul



- aruncarea cu zarul se numește **experiment**; faptul că iese fața 1 este un **eveniment**
- evenimentului “a ieșit fața 1” îi asociem o probabilitate cuprinsă între 0 și 1 ( $1/6$  în cazul unui zar corect)
- exemplu de evenimente: număr par -  $\{2, 4, 6\}$  sau număr impar -  $\{1, 3, 5\}$
- probabilitatea evenimentului sigur (să iasă un număr la aruncarea cu zarul) este 1
- probabilitatea evenimentului imposibil (acum plouă cu bani) este 0
- evenimentul compus din două evenimente mutual exclusive (fie iese par fie iese impar) este suma probabilităților celor două evenimente

## Evenimente mutual exclusive



- evenimentele A și B nu pot apărea simultan
- $P(A \cup B) = P(A) + P(B)$

- reguli simple dar suficiente pentru a deduce de aici toate regulile pe care le urmează probabilitățile (Kolmogorov)


# Regulile probabilităților

- ① probabilitatea evenimentului imposibil este 0
  - ex. la zar, probabilitatea să iasă un număr mai mare ca 6
- ② probabilitatea evenimentului sigur este 1
  - ex. probabilitatea să iasă un număr între 1 și 6
- ③ probabilitatea ca opusul unui eveniment să apară este  $1 - (\text{probabilitatea celui eveniment})$ 
  - ex. probabilitatea să iasă un număr par este  $1 - (\text{probabilitatea să iasă un număr impar})$
- ④ probabilitatea ca să apară cel puțin unul din mai multe evenimente mutual exclusive<sup>1</sup> să apară este suma probabilităților lor
- ⑤ dacă producerea unui eveniment A implică producerea unui eveniment B, atunci probabilitatea ca A să apară e mai mică decât probabilitatea ca B să apară

---


<sup>1</sup>care nu pot să apară simultan

# Eveniment dependent



- producerea evenimentului A implică producerea lui B (dacă A s-a produs, atunci sigur și B s-a produs pentru că A este parte din B)
- ex. dacă a apărut evenimentul “fața 2”, atunci sigur a apărut și evenimentul “față număr par”
- A este un subset al lui B
- $P(B) > P(A)$  pentru exemplul cu zarul

## Evenimente ne-independente



- cele două evenimente nu sunt mutual exclusive
- suma probabilităților lor include intersecția de două ori
- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- probabilitățile nu se pot aduna dacă evenimentele asociate lor au o intersecție nevidă

6 pentru orice două evenimente, probabilitatea ca cel puțin unul dintre ele să apară este suma probabilităților lor minus intersecția

## Exemplu de evenimente cu intersecție nevidă

- Un studiu relevă faptul că 3% din populația adultă are apnee în somn. Un alt studiu afirmă că 10% din populația adultă manifestă “sindromul piciorului neliniștit” în somn. Putem afirma că 13% din populația adultă are cel puțin una din probleme cu somnul de acest gen?

## Exemplu de evenimente cu intersecție nevidă

- Un studiu relevă faptul că 3% din populația adultă are apnee în somn. Un alt studiu afirmă că 10% din populația adultă manifestă “sindromul piciorului neliniștit” în somn. Putem afirma că 13% din populația adultă are cel puțin una din probleme cu somnul de acest gen?
- Nu, pentru că este posibil ca o anumită fracție din populație să aibă ambele tipuri de probleme, și atunci fracția din populație care manifestă cel puțin una din probleme să fie mult mai mică (cel puțin cât?)

# Densități de probabilitate

- Axiomele (regulile) probabilităților sunt utile pentru înțelegerea regulilor pe care probabilitățile le urmează
- Totuși avem nevoie de modele cu ajutorul cărora să definim rezultatele numerice ale experimentelor
- ne interesează densities și mass functions pentru variabile aleatoare
  - **probability mass function** se referă la probabilități asociate evenimentelor discrete (aruncarea zarului)
  - **probability density function** se referă la probabilitatea asociată variabilelor continue (evenimentul “cantitatea de apă de ploaie dintr-o zi”)
- ce se estimează nu sunt apariții punctuale în date, ci proprietăți ale populației din care observăm un sample (un număr limitat de indivizi)



# Variabile aleatoare

- o **variabilă aleatoare** este rezultatul numeric al unui experiment
- ele pot fi **discrete** sau **continue** (exemple: culoarea părului)
- pentru variabile discrete, asignăm probabilități valorilor pe care le pot lua
- pentru variabile continue, asignăm probabilități intervalelor de valori pe care acestea le pot lua
- exmple de variabile discrete: evenimentul față de monedă, sau față de zar, numărul de vizitatori zilnici ai unui site
- exemple de variabile continue: BMI, IQ

# PMF

- Probability Mass Function e o funcție, ce dă valoarea probabilității pentru cazul în care variabila aleatoare ia o anumită valoare
- această funcție  $P(\cdot)$  trebuie să satisfacă:
  - trebuie să fie mai mare sau egală cu 0
  - suma valorilor probabilităților pe care variabila aleatoare poate să le ia trebuie să aibă suma 1

- problema zarului:

$$P(1) = 1/6 = P(X = 1)$$

$$P(2) = 1/6 = P(X = 2)$$

...

$$P(6) = 1/6 = P(X = 6)$$

$$P(X = 1) + P(X = 2) + \dots + P(X = 6) = 1$$

## PMF pentru coin flip - distribuția Bernoulli

$X = 0$  reprezintă tails iar  $X = 1$  reprezintă heads<sup>2</sup>

$p(x) = (1/2)^x(1/2)^{1-x}$ , unde  $x$  este o variabilă<sup>3</sup>,  $x = 0, 1$

$$p(0) = (1/2)^0(1/2)^{1-0} = 1/2$$

$$p(1) = (1/2)^1(1/2)^{1-1} = 1/2$$

- pentru o monedă trucată, avem:

$$p(x) = \theta^x(1 - \theta)^{1-x}, \text{ for } x = 0, 1$$

$$p(0) = \theta^0(1 - \theta)^{1-0} = 1 - \theta$$

$$p(1) = \theta^1(1 - \theta)^{1-1} = \theta$$

- exemplu, acest  $p(\cdot)$  poate descrie prevalența hipertensiunii într-o populație; dar nu cunoaștem  $\theta$ , putem folosi datele pentru a-l estima<sup>4</sup>


<sup>2</sup>litera mare  $X$  reprezintă o valoare potențială, nerealizată, a variabilei aleatoare

<sup>3</sup>placeholder folosit pentru a plasa valoarea asociată evenimentului realizat

<sup>4</sup>tehnica se numește Maximum Likelihood Estimation, alegem  $\theta$  astfel ca datele să se potrivească cel mai bine

# PDF

- o funcție a densității de probabilitate este o funcție asociată cu o variabilă aleatoare continuă
- ca și PMF, va satisface anumite proprietăți:
  - 1 mai mare sau egală cu zero peste tot (în domeniul de definiție)
  - 2 aria totală de sub funcție trebuie să fie 1 (Area Under Curve, AuC)
- ariile de sub PDFs corespund cu probabilitățile pentru acea variabilă aleatoare




- probabilitatea ca o persoană să aibă IQ între 100 și 110
- PDF e un atribut al populației coeficientului de inteligență, nu o afirmație despre date
- vom folosi datele să deducem însușiri ale populației

## PDF (2)

- pentru PDF, probabilitatea ca variabila aleatoare să ia EXACT o anumită valoare (ex. 100, în exemplul de mai sus), e ZERO
- a nu se confunda cu PMF !
- densitatea de probabilitate normală este denumită și densitate de probabilitate gaussiană, sau “bell-shaped curve”, sau “clopot”, sau “pălărie”
- denumită și distribuție normală, ea este caracterizată de două valori: media  $\mu$  și dispersia (sau deviația standard)  $\sigma$
- în exemplul anterior,  $\mu = 100$  iar  $\sigma = 6$  (aproximativ)

# Exemplu de PDF

$$f(x) = \begin{cases} 2x & \text{daca } 0 < x < 1 \\ 0 & \text{altfel} \end{cases}$$



- $f(x)$  exprimă proporția de apeluri care este satisfăcută de linia call center într-o zi oarecare
- este o densitate de probabilitate validă? (cele 2 proprietăți)
- care este probabilitatea ca mai puțin din 75% din apeluri să fie satisfăcute? aria:

$$1.5 * 0.75 / 2 = 0.5625$$

```
>> stats.beta.cdf(0.75, 2, 1)
```

```
0.5625
```

# CDF și Survival Function

- Cumulative Distribution Function (CDF) pentru o variabilă aleatoare  $X$ , este probabilitatea ca variabila aleatoare să fie mai mică sau egală cu valoarea  $x$  (mic):

$$F(x) = P(X \leq x)$$

- definiția se aplică atât pentru variabile discrete cât și pentru cele continue:

```
>> stats.beta.cdf(0.75, 2, 1)
0.5625
```


- funcția SciPy `beta.cdf()` va da probabilitatea ca variabila să fie mai mică decât valoarea dată
- Survival Function:  $S(x) = P(X > x) = 1 - F(x)$

```
>> stats.beta.cdf([0.4, 0.5, 0.6], 2, 1)
[0.16 0.25 0.36]
```

# Quantiles


- nota la un examen este quantila 95%, înseamnă că 95% din candidați au avut note mai mici respectiv 5% note mai mari - acestea sunt "sample quantiles"
- quantila  $\alpha$  a unei funcții de distribuție  $F$  este punctul  $x_\alpha$  astfel încât:

$$F(x_\alpha) = \alpha$$




- se deplasează  $x$  până când aria  $F(x) = \alpha$
- aria e de fapt CDF (aria totală = 1)
- **percentila** e de fapt o quantilă exprimată ca procent
- mediana este percentila 50





$$F(x) = P(X \leq x) = \frac{1}{2} \text{Base} * \text{Height} = \frac{1}{2}(x) * (2x) = x^2$$



- în 50% din zile, 70% din apeluri sau mai puține sunt satisfăcute

- aria hașurată exprimă probabilitatea ca mai puțin de 75% din apeluri să fie satisfăcute
- dorim să aflăm care este proporția de apeluri ce corespunde unei probabilități de 50%


$$0.5 = F(x) = x^2$$

```
>> math.sqrt(0.5)
0.7071067
>> stats.beta.ppf(0.5, 2, 1)
# ppf - percent point function
0.7071067
```

# Estimatori

- de obicei, noțiunea de mediană se realiza folosind ordonarea crescătoare a datelor și folosirea elementului de la mijloc
- aici, mediana sample-ului va estima mediana populației
- de exemplu, putem lua mai multe zile, și aflăm proporția de apeluri satisfăcute
- apoi facem mediana acestor proporții, și vom aproxima astfel mediana populației
- mediana populației se numește estimand, iar mediana sample-ului folosit de noi se numește estimator

# Conditional risk



THE ANNUAL DEATH RATE AMONG PEOPLE  
WHO KNOW THAT STATISTIC IS ONE IN SIX.

# Probabilități condiționate

- la zar, probabilitatea să iasă 1 este  $1/6$
- presupunem că știm că fața este număr impar
- folosind această nouă informație, probabilitatea să iasă 1 este .. ?

# Probabilități condiționate

- la zar, probabilitatea să iasă 1 este  $1/6$
- presupunem că știm că fața este număr impar
- folosind această nouă informație, probabilitatea să iasă 1 este .. ?
- $1/3$

## Probabilități condiționate (2)

- fie B un eveniment astfel ca  $P(B) > 0$

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

- dacă A și B sunt independente statistic, atunci:

$$P(A|B) = \frac{P(A)P(B)}{P(B)} = P(A)$$

- în acest ultim caz, faptul că B a apărut nu dă informații suplimentare despre A

## Probabilități condiționate (3)

- $A = \{1\}, B = \{1, 3, 5\}$
- $P(1 \text{ dacă a ieșit un număr impar}) = P(A|B)$
- $P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A)}{P(B)} = \frac{1/6}{3/6} = \frac{1}{3}$



# Regula lui Bayes

- Thomas Bayes, matematician și teolog, Anglia sec. XVIII
- ne permite inversarea rolurilor evenimentelor pentru care vrem să aflăm probabilitățile
- vrem să calculăm  $P(B|A)$  dacă avem  $P(A|B)$

$$P(B|A) = \frac{P(A|B)P(B)}{P(A)} \quad \text{respectiv:}$$

$$= \frac{P(A|B)P(B)}{P(A|B)P(B) + P(A|B^c)P(B^c)}$$

- se poate privi  $P(A)$  ca fiind alcătuită din două evenimente mutual exclusive,  $P(A|B)$  respectiv  $P(A|B^c)$ , când se întâmplă și nu se întâmplă B

# Teste și diagnostice

- fie  $+$  și  $-$  evenimentele ca un rezultat al unui test pentru diagnostic să fie pozitiv sau negativ
- fie  $D$  și  $D^c$  evenimentul ca subiectul testului să aibă sau nu boala pentru care se testează

*Sensitivity* =  $P(+|D)$ , vrem să fie ridicată

*Specificity* =  $P(-|D^c)$ , la fel, ridicată pentru ca testul să fie considerat bun

## Teste și diagnostice (2)

- suntem interesați, dacă are boala, ca testul să fie pozitiv:

Positive predictive value =  $P(D|+)$

Negative predictive value =  $P(D^C|-)$

- în absența testului:

Prevalence of disease =  $P(D)$

## Teste și diagnostice (3)

- considerăm că avem un test HIV cu următoarele valori ipotetice:
  - sensitivity de 99.7%
  - specificity de 98.5%
- în populație, prevalența bolii este de 0.1%
- dacă testul iese pozitiv, care este probabilitatea ca respectivul chiar să aibă boala?

$$P(D|+) = ?$$

# Teste și diagnostice - Bayes

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|D^C)P(D^C)}$$

- putem exprima totul în funcție de sensitivity  $P(+|D)$  și specificity  $P(-|D^C)$ :

$$\begin{aligned} &= \frac{P(+|D)P(D)}{P(+|D)P(D) + \{1 - P(-|D^C)\}\{1 - P(D)\}} \\ &= \frac{.997 \times .001}{.997 \times .001 + .015 \times .999} = .062 \end{aligned}$$

## Teste și diagnostice - Bayes (2)

- valoarea scăzută a positive predictive value  $P(D|+)$  este cauzată de prevalența scăzută a bolii în populație
- pe de altă parte, dacă știm că respectivul este un consumator de droguri, această probabilitate crește (prevalența HIV în rândul consumatorilor de droguri)

$$\begin{aligned}
 &= \frac{P(+|D)P(D)}{P(+|D)P(D) + \{1 - P(-|D^c)\}\{1 - P(D)\}} \\
 &= \frac{.997 \times .001}{.997 \times .001 + .015 \times .999} = .062
 \end{aligned}$$

# Likelihood ratios

- vrem să distingem între componenta dependentă de această prevalență și componenta descrisă ca rezultat obiectiv al testului - likelihood ratio
- positive predictive value:

$$P(D|+) = \frac{P(+|D)P(D)}{P(+|D)P(D) + P(+|D^C)P(D^C)}$$

- formula depinde de specificity, 1 - sensitivity și prevalența bolii ( $P(D)$ )
- putem exprima cu Teorema Bayes  $1 - P(D|C) = P(D^C|+)$ , probabilitatea de a nu avea boala dacă testul iese pozitiv:

$$P(D^C|+) = \frac{P(+|D^C)P(D^C)}{P(+|D)P(D) + P(+|D^C)P(D^C)}$$

## Likelihood ratios (2)

- prin împărțire directă, obținem:

$$\frac{P(D|+)}{P(D^C|+)} = \frac{P(+|D)P(D)}{P(+|D^C)P(D^C)} = \frac{P(+|D)}{P(+|D^C)} \times \frac{P(D)}{P(D^C)}$$

- prima parte se numește șansa (proporția) bolii dat fiind rezultatul
- ultima parte este șansa (proporția) bolii în lipsa testului
- termenul din mijloc este diagnostic likelihood ratio a rezultatului unui test pozitiv
- post-test likelihood = diagnostic likelihood ratio<sup>5</sup> × pre-test likelihood

---

<sup>5</sup> $DLR_+$



## Likelihood ratios (3)

- pentru exemplul inițial:

$$DLR_+ = .997 / (1 - .985) = 66$$

- indiferent de proporția pre-test, se înmulțește cu 66 pentru obținerea proporției post-test
- ipoteza bolii este suportată de date de 66 de ori mai puternic decât ipoteza lipsei bolii

# Evenimente independente

- evenimentele  $A$  și  $B$  sunt zise independente dacă:

$$P(A|B) = P(A), \text{ unde } P(B) > 0$$

sau

$$P(A \cap B) = P(A)P(B)$$

- probabilitățile nu se pot multiplica oricând, ci se multiplică doar probabilitățile evenimentelor independente

## Evenimente independente (2)

- exemplu: probabilitatea de a obține de două ori Head?

$A = \{\text{Head la prima aruncare}\}, P(A) = .5$

$B = \{\text{Head la a doua aruncare}\}, P(B) = .5$

$A \cap B = \{\text{Heads la ambele aruncări}\}$

$P(A \cap B) = P(A)P(B) = .5 \times .5 = .25$


## Evenimente ne-independente (3)

- în 1999, Sally Clark, a fost condamnată pentru crimă împotriva propriilor copii (doi), decedați la vâsta de 2 și 3 luni
- apărarea a pledat pentru “Sudden Infant Death Syndrome”
- <https://understandinguncertainty.org/node/545>
- prevalența SIDS este de 1 din 8543
- expertul a considerat cele două morți evenimente independente
- șansa ca două să se producă:  $(1/8543)^2$  aprox. 1 la 73 milioane
- pe baza acestei argumentații a fost condamnată - eroare judiciară
- evenimentele de acest gen care au un mediu sau componentă genetică comună, nu sunt independente

# Variabile aleatoare IID

- variabilele aleatoare sunt zise IID dacă sunt independente și identically distributed
- independente: statistic nelegate între ele
- distribuite identic: toate sunt extrase din aceeași distribuție (populație)
- mai multe aruncări de monede sunt IID
- modelul IID este modelul implicit pentru sample-uri extrase aleator

# Monty Hall game show



- fiecare uşă ascunde fie maşina, fie o capră
- inițial alegem o uşă
- prezentatorul deschide o uşă cu o capră (întotdeauna)
- prezentatorul ne oferă să schimbăm uşa; o facem?

<https://www.youtube.com/watch?v=8DMnAAvakh0> The '21' movie fragment

# Monty Hall și probabilitățile condiționate

- notăm cu  $A$  evenimentul ca mașina să se afle în spatele ușii 1
- notăm cu  $B$  evenimentul ca prezentatorul să deschidă ușa 2 (el întotdeauna deschide o ușă în spatele căreia se află o capră)
- probabilitatea ca în spatele ușii 1 să se afle mașina este  $P(A) = 1/3$
- pe noi ne interesează ce s-a schimbat cu  $A$  în cazul în care se întâmplă  $B$ :

$$P(A|B) = \frac{P(A, B)}{P(B)} \quad (1)$$

## Monty Hall și probabilitățile condiționate (2)

- probabilitatea ca să se întâmple simultan  $A$  și  $B$ , adică mașina să fie în spatele ușii 1 și el să deschidă ușa 2 (atenție, nu sunt independente!), se calculează folosind teorema Bayes:

$$P(A, B) = P(B|A) * P(A) = \frac{1}{2} * \frac{1}{3} = \frac{1}{6} \quad (2)$$

- $P(B|A)$  este probabilitatea ca el să deschidă ușa 2 dacă mașina e în spatele ușii 1 (ceea ce se întâmplă în jumătate din cazuri)



## Monty Hall și probabilitățile condiționate (3)

- $P(B)$  se evaluează folosind probabilitățile marginale (condiționate), adică ținem seama de apariția (sau nu) a evenimentului A:

$$P(B) = P(B|A)P(A) + P(B|A^c)P(A^c) \quad (3)$$

- prima parte  $P(B|A)P(A) = P(A, B) = \frac{1}{6}$  am calculat-o mai sus
- a doua parte este  $P(B|A^c)P(A^c) = P(B, A^c)$  și exprimă probabilitatea ca să deschidă ușa 2 și mașina să nu se afle în spatele ușii 1

## Monty Hall și probabilitățile condiționate (4)

- probabilitatea ca să deschidă ușa 2 și mașina să se afle în spatele ușii 1,  $P(B, A^c)$ , este dată de două situații:
  - mașina să se afle în spatele ușii 2 și atunci nu deschide ușa;
  - mașina să se afle în spatele ușii 3 și atunci deschide ușa:

$$P(B, A^c) = \frac{1}{3} * 0 + \frac{1}{3} * 1 = \frac{1}{3} \quad (4)$$

- reluând, avem:

$$P(A|B) = \frac{P(A, B)}{P(B)} = \frac{\frac{1}{6}}{\frac{1}{6} + \frac{1}{3}} = \frac{\frac{1}{6}}{\frac{1}{6} + \frac{2}{6}} = \frac{1}{1 + 2} = \frac{1}{3} \quad (5)$$

- deci șansele noastre nu s-au îmbunătățit dacă nu schimbăm ușa
- din contra, probabilitatea ca mașina să nu se afle în spatele ușii 1 dacă el deschide ușa 2 este:

$$P(A^c|B) = 1 - P(A|B) = \frac{2}{3} \quad (6)$$

# Bibliografie

- <https://www.norwegiancreations.com/2018/10/bayes-rule-and-the-monty-hall-problem/>
-